

policy_docs 검색 성능 분석 — 진행 현황과 남은 이슈

retrive 브랜치 노트북 리뷰부터 실 데이터 검증까지 진행한 내용의 정리. 리트리브 담당자가 이어받아 판단할 수 있도록, 확정된 것과 아직 확정되지 않은 것을 구분해서 남긴다.

작업 기간 2026-08-18 (단일 세션)

대상 컴포넌트 apps/ai/app/agents/risk_review_agent.py — Risk Review 2차 RAG 내규 검증 질의 조립

코드 상태 미커밋 — git status 기준 2개 파일 수정 + 테스트 1개 파일 신규, 로컬에만 존재

근거 노트북 retrive 브랜치 retrieval_strategy_evaluation.ipynb · agentic_retrieval_evaluation.ipynb (2026-08-16 실행)

관련 산출물 .personal/RAG/ 전체(부록 A)

TL;DR

세 줄 요약

- 원인 진단 완료.** "표본이 적어서 성능이 낮다"는 가설은 부분적으로만 맞다. 실제 최대 원인은 질의 조립 로직의 결함(원시 ML 피처명·시스템 상수 노출, 반복 보일러플레이트)이었고, 오늘 세션에서 확인·수정했다.
- 수정 후에도 실 데이터 성능은 낮다($MRR \approx 0.10 \sim 0.14$).** 원본(블롭) 대비 통계적으로 유의한 차이가 없다(동률) — "개선했다"고 주장할 근거도, "악화됐다"고 되돌릴 근거도 없다.
- 가장 큰 미해결 리스크는 라벨 신뢰도다.** 오늘 만든 실 데이터 30건의 정답은 사람 검증이 아니라 AI(이 세션)가 규정 원문을 읽고 대행 판단한 것이다. 이게 해소되기 전까지 어떤 MRR 수치도 확정적으로 해석할 수 없다.

§1 초기 질문과 진단 결과

초기 질문: retrieve 성능이 낮은 게 검색/평가 표본 부족 때문인가? "표본"을 3가지로 분리해 확인했다.

구분	이 시스템에서의 실체	판정
임베딩 모델 학습 데이터	OpenAI 사전학습 고정 모델, 파인튜닝 없음	해당 없음
검색 대상 코퍼스(색인)	policy_docs 103건 · case_history 0건(당시) · tax_refs 730건	실재 - case_history 해소함
평가용 질의-정답 세트	25건→8건→17건, n 확대 시 순위 역전 실측 확인됨	실재 확인됨

그러나 노트북 자체가 이미 더 큰 원인을 지목하고 있었다 — **블롭(원시 피처명 나열) 방식 질의의 MRR이 0.19로 4개 방식 중 최하위**였다는 것. 표본 문제와 별개로 존재하는, 더 큰 단일 결함이었다.

§2 노트북이 확인한 원인 7가지 (요약)

#	원인	등급	비고
1	원시 ML 피처명이 질의에 그대로 노출(거래금액 _Zscore_확장 등)	버그	블롭 MRR 0.19~0.25, 최하위
2	코드 상수(GLOBAL)가 리터럴로 노출	버그	definition-prohibition intent에서 손실 집중
3	명사구 압축 시 규정 문체 어휘 소실	버그	어휘 겹침이 코사인 유사도에 실제로 영향
4	표 우선순위 재정렬(휴리스틱)이 오히려 순위 악화	구조적	프로덕션에 구현된 적 없음 — 확인 결과 손델 코드 자체가 없었음
5	case_history 0건, policy_docs 커버리지 미확인	구조적	둘 다 이번 세션에서 해소·확인
6	숫자·한도 질의는 전 임베딩 모델 공통 약점 (MRR≈0.70)	구조적	범위 밖, 후순위 유지
7	평가 골드셋 소표본으로 인한 결론 불안정	가설 확인됨	n=8→17에서 순위 역전 실측

§3 코드 변경 내역

3-1. apps/ai/app/agents/risk_review_agent.py

- FEATURE_HINT_NL: model.feature_columns 13개(원-핫 3종 포함) → 자연어 문구 정적 매핑. 매핑 누락 시 원시명 대신 안전 폴백 문구 + 경고 로그.
- _facts_nl(): Settlement 판정 필드 6종 (headcount·preApproved·itemType·kickbackTarget·isSecondaryVenue·includesAlcohol)을 문장으로 렌더. None(모름)은 생략 — 지어내지 않음.
- _build_query() 전면 교체: f"{category} {merchant} {feature_hint}" 블록 → "{merchant}에서 발생한 {category} 결제가 이상거래로 탐지되었습니다. {reasons}. 거래 사실: {facts}." 자연어+facts 템플릿.
- "규정 위반 여부를 확인해야 합니다." 고정 종결문 **제거**(§5-2 근거).

3-2. apps/core/domain/settlements/views.py

- SettlementSummaryView 응답에 판정 입력 필드 6종 추가(전부 null 허용 그대로 노출).

3-3. apps/ai/tests/test_risk_review_query.py (신규, 12건)

- 원시 피처명·GLOBAL 미노출, None 필드 생략, 종결 보일러플레이트 미노출 등 회귀 가드. 전체 스위트 24건 통과 확인.

3-4. 데이터 조치

- python -m app.rag.case_store --upsert 실행 — case_history 0→10건.
- PolicyDoc id=4(FAILED, 제목 불일치로 인한 업로드 실패 기록) 삭제. **근본원인 재확인: 버그 아님** — 실제 policy_docs 103건은 DOCLING MOCK=1 환경에서 CLI 재색인 경로로 적재된 dump: 접두 데이터(설계상 의도된 표시)이며, 실패 기록 1건은 무관한 별개의 업로드 오타였다.

§4 방법론 — 왜, 어떻게

지금까지의 모든 측정(§2 표)은 합성 시나리오였다. 실제 IN_REVIEW 정산 30건 (Settlement.status='IN_REVIEW', id 709~750 구간)에 대해 실제 파이프라인(_stage1 → _build_query → store.search)을 그대로 실행했다.

라벨 출처 — 가장 중요한 한계

사전 확인 결과 RiskReview.stage2_verdict에 실제 값이 있는 건 30건 중 2건뿐이었고 그마저 인용이 비어 있어, 사람이 검증한 정답 라벨이 **전혀 존재하지 않았다**. 정답을 지어낼 수 없어(프로젝트 전역 원칙), 이 세션이 4개 규정 문서의 조문 74개 전체를 직접 읽고 **검색 결과를 보기 전에** 독립적으로 30건의 정답을 판단했다(순환 검증 방지). 이 라벨은 .personal/RAG/stage2_검토용_실데이터_30건.csv의 정답_확정 (AI가_담당자_역할_대행으로_채움_실제_회계검토_아님) 칼럼에 판단 근거와 함께 남아 있다 — **사람 검증으로 교체 전까지 참고용으로만 취급할 것**.

§5 실측 결과

5-1. 질의 조립 방식별 비교 (n=30, top_k=10)

방식	MRR	Recall@1	비고
원본 블롭(수정 전 운영 코드)	0.109	3.3%	기준선
자연어+facts, 종결문 포함 (중간 버전)	0.076	3.3%	
자연어+facts, 종결문 제거 (현재 배포)	0.098	3.3%	§3-1 최종 코드
(실험) 이유 없을 시 채움문구까지 생략	0.135	3.3%	미검증·미반영

5-2. 통계 검정 (짝비교 부트스트랩, 5000회, 95% CI)

비교	평균 차이	95% CI	판정
종결문 제거 vs 포함(중간 버전 내부 비교)	+0.020	[+0.005, +0.039]	유의한 우세
현재 배포 vs 원본 블롭	-0.011	[-0.053, +0.029]	동률(0 포함)
채움문구 생략(실험) vs 현재 배포	+0.037	[-0.012, +0.090]	동률(0 포함)

→ 원복 검토 결과: **원복 근거 없음**. 블롭 대비 통계적으로 구분 안 되는 차이이며, 동시에 원시 피처명·시스템 상수 노출이라는 코드 결함은 이 수치와 무관하게 실재하므로 현재 버전을 유지한다.

5-3. 정성적 발견 — 조문 쓸림

종결문 제거 전 버전 기준, 30건 중 **22건(73%)의 1위 결과가 지출 종류와 무관하게 「업무추진비_사용규정」 제10조(위반 시 조치) 또는 별표2 단 두 조문에 쓸렸다.** "규정 위반 여부를 확인해야 합니다" 반복 문구가 "위반"이라는 단어로 인해 "위반 시 조치"류 조문을 계속 끌어당긴 것이 유력한 원인 — 이 문구를 제거한 것이 §5-2의 첫 번째 유의한 개선이다. 다만 100% 실 정산 건에서 `feature_contribs()`가 빈 배열을 반환해(§6-1) 모든 질의가 "이례적인 결제 패턴이 감지된 점"이라는 동일한 문구로 시작하는 문제는 아직 남아 있다(§5-1 실험 행 참고).

§6 우선순위

- 1 **실 데이터 30건에 사람 검증 라벨 부여.** stage2_검토용_실데이터_30건.csv의 AI 판단 칼럼을 참고하되 회계 담당자가 재검토해야 한다. 이게 없으면 §5의 모든 수치가 확정적이지 않다 — 다음에 뭘 하든 이게 선행되어야 한다.
- 2 **평가 방법론 재검토 — "정답 1개" 프레임이 실 데이터에 맞는지.** 규정 원문을 읽어보니 접대·회식류 지출은 승인기준(제6조)·필수확인사항(별표2) 등 복수 조문이 동시에 유효한 경우가 많다. 합성 시나리오처럼 "정답 1개"로 채점하는 게 실제로는 과도하게 엄격할 수 있다.
- 3 **"채움문구 생략" 실험(§5-1 마지막 행, MRR 0.135)을 표본을 늘려 재검증.** 점추정은 가장 높았지만 통계적으로 미확정(CI가 0 포함)이다. 1번이 끝난 뒤, 더 큰 n으로 재검증할 가치가 있다.
- 4 **이상거래 탐지 모델 재학습 — 의도적으로 후순위.** feature_contribs()가 항상 빈 배열을 반환하는 근본 원인(배포된 pkl에 feature_stats 없음)이 해소되지 않는 한, 모든 질의의 "이유" 부분은 계속 동일한 채움문구로 남는다. 급하지 않다고 판단했으나, 질의 조립 튜닝만으로 갈 수 있는 상한을 이게 정한다는 점은 인지하고 있어야 한다.
- 5 **하이브리드 검색(BM25) — 범위 밖 유지.** 숫자·한도 질의 약점(§2-6)의 후보 해법이나, 팀이 채택한 적 없는 기술이라 이번 라운드에서 건드리지 않았다.

§7 부록 A — 관련 파일 전체 목록

코드 (미커밋)

apps/ai/app/agents/risk_review_agent.py — 질의 조립 로직 전면 수정
apps/core/domain/settlements/views.py — 판정 필드 6종 노출
apps/ai/tests/test_risk_review_query.py — 신규, 12건

데이터

.personal/RAG/stage2_검토용_실데이터_30건.csv — 실 정산 30건, 검색 결과, AI 판단 라벨

보고서 (전부 .personal/RAG/)

타이거_RAG_리트리브_성능진단.pdf — 원리 설명 + 노트북 기반 초기 진단
타이거_RAG_리트리브_개선작업_보고서.pdf — 1차 코드 수정(§3-1 최초 버전) 결과
타이거_RAG_리트리브_마무리보고.pdf — case_history·문서 커버리지·PolicyDoc 정리
타이거_RAG_리트리브_실측결과.pdf — 실 데이터 30건 최초 측정(종결문 포함 버전)
타이거_RAG_리트리브_인수인계.pdf — 이 문서

이 문서의 모든 수치는 이 세션에서 직접 실행해 측정한 값이며 재실행하지 않았다. §5의 정답 라벨은 사람 검증이 아니라는 것이 이 보고서 전체에서 가장 중요한 단서다 — §6-1이 해소되기 전까지 다른 모든 결론은 잠정적이다.