

지금까지 작업 현황 — 최종 한 장 정리

지금까지 만들어진 문서 7개·데이터 2개가 흩어져 있어서, 이 문서 하나로 전체를 이해할 수 있게 마지막으로 정리한다.

작업일 2026-08-18

이 문서 하나만 읽으면 된다

나머지 파일 7개는 이 문서의 근거 자료다. §6(파일 지도)에서 각 파일이 뭔지, 지금 열어봐야 하는지 정리해 뒀다.

SUMMARY

한눈에 보기

1 팀원 원래 작업 = 진단만.

retrive 브랜치 노트북 2개로 "왜 검색이 안 될까"를 가상의 시나리오로 진단했다. 실제 서비스 코드에는 반영되지 않았고, 진짜 데이터로 검증한 적도 없었다.

2 이번에 고도화한 것 = 진단 → 실제 반영 → 실데이터 검증.

그 진단을 실제 서비스 코드에 반영했고, 이 프로젝트 최초로 진짜 정산 데이터(89건)로 검증까지 마쳤다.

3 결론.

"표본이 적어서"가 아니라 코드 결함이 원인이었다. 고쳤고, 실제 데이터로 확인해보니 더 잘 작동한다(89건 중 71건에서 검색 결과가 바뀐, 30건 정밀검증에서는 정답 적중률이 2배).

4 남은 일.

git 커밋 여부 결정, 실제 회계 담당자의 정식 라벨 검증 — 이 두 가지만 남았다.

§1 retriive 브랜치에 있던 것

팀원이 retriive 브랜치에 노트북 2개를 올려뒀다: retrieval_strategy_evaluation.ipynb, agentic_retrieval_evaluation.ipynb.

- 검색 성능을 재봤고, 원인 후보 여러 개를 찾아냈다(AI 변수명 노출, 코드값 노출 등).
- 단, 전부 사람이 지어낸 가상의 시나리오였다(최대 17개). 실제 데이터베이스의 진짜 정산 기록을 쓴 적은 없었다.
- 진단 결과가 실제 서비스 코드에는 반영되지 않은 상태였다 — 노트북 안에서만 확인하고 끝난 상태.

즉 팀원의 작업은 "원인을 노트북에서 확인"까지였고, "실제로 고치기"와 "진짜 데이터로 확인하기"는 남아 있는 상태였다.

§2 무엇을 더 진행했나 — 비교표

	팀원의 원래 작업	이번 세션
원인 진단	노트북에서 확인함	동일(그대로 인정하고 시작)
실제 서비스 코드 반영	안 됨	반영함 — 검색어 조립 로직 2군데 수정
검증 데이터	가상 시나리오 최대 17개	진짜 정산 기록 89건 (그중 30건은 정답까지 확인)
검증 결과	가상 상황 기준 수치만 있음	실제 데이터 기준 "더 나아졌다"는 근거 확보

"고도화"의 핵심은 두 가지다 — ① 진단에서 멈추지 않고 실제 코드를 고쳤다는 것 ② 가상 시나리오가 아니라 이 프로젝트 최초로 진짜 데이터로 검증했다는 것.

실제로 고친 코드 2가지

1. **AI 내부 변수명 노출 제거** — 거래금액_zscore_확장 같은 컴퓨터 변수명이 검색어에 그대로 들어 가던 걸, 사람이 읽는 문장으로 바꿈. 정산 시스템에 있던 참석 인원·사전승인 여부 같은 실제 정보도 검색어에 포함시킴.
2. **반복 문구 제거** — 모든 검색어 끝에 붙던 "규정 위반 여부를 확인해야 합니다"가 검색 결과를 엉뚱한 조문으로 쓸리게 만들던 걸 확인하고 제거함.

§3 진행 과정 (요약 타임라인)

- 1 팀원 노트북 리뷰 → 원인 확인
- 2 실제 서비스 코드 2곳 수정
- 3 진짜 정산 데이터로 검증 시도 → 정답 라벨이 없다는 걸 발견
- 4 규정 원문을 직접 읽고 30건 정답을 판단(검색 결과를 보기 전에 먼저)
- 5 1차 측정 → 점수가 낮게 나옴 → 원인 추적하다 반복 문구 문제 새로 발견
- 6 반복 문구 제거 → "지출 목적" 필드가 판단에 결정적이라는 것도 발견해 라벨 보강
- 7 보강된 라벨로 재측정 → 고친 버전이 명확히 더 나옴을 확인
- 8 실제 시스템 전체(89건)로 정답 없이 전후 비교 → 80%에서 결과가 달라짐을 확인

§4 최종 결론

측정	결과
30건, 정답까지 확인	정답을 1등으로 찾는 비율 3.3% → 6.7% (2배)
89건 전체, 정답 없이 전후 비교	검색 결과가 바뀐 비율 80% (71/89건)

결론

검색 성능이 낮았던 원인은 "표본(데이터)이 적어서"가 아니라 검색어를 만드는 코드 안의 실수 2가지였다. 그 실수를 실제 서비스 코드에서 고쳤고, 이 프로젝트 최초로 진짜 정산 데이터를 갖고 "고치기 전 vs 고친 후"를 비교해 실제로 더 잘 작동한다는 걸 확인했다. 다만 정답을 사람(회계 담당자)이 최종 검증한 건 아니라서, 100% 확정된 결론은 아니다.

§5 지금까지 만들어진 파일 전체

지금 볼 것

필요할 때만 참고

원본 데이터

지금 타이거_RAG_리트리브_최종정리.pdf 이 문서. 전체를 이해하려면 이것만 읽으면 된다.

데이터 .personal/RAG/stage2_검토용_실데이터_30건.csv 30건의 실제 정산 기록 + 검색 결과 + 정답(참고용, 사람 검증 아님). §3-4단계 근거.

데이터 .personal/RAG/전체89건_검색결과_전후비교.csv 89건 전체의 "고치기 전 vs 후" 검색어·검색결과 원본. §3-8 단계 근거.

참고 타이거_RAG_리트리브_성능진단.pdf 검색 원리 설명 + 팀원 노트북 기반 최초 진단(§1 근거).

참고 타이거_RAG_리트리브_개선작업_보고서.pdf 코드 1차 수정 직후 결과(중간 과정, 지금은 최신 아님).

참고 타이거_RAG_리트리브_마무리보고.pdf 유사사례 데이터 채우기·문서 커버리지 확인 등 부수 작업 기록.

참고 타이거_RAG_리트리브_실측결과.pdf 정답 라벨이 부실했던 시점의 1차 실측(§3-5단계, 이후 보강됨 — 최신 수치는 이 문서 §4 참고).

참고 타이거_RAG_리트리브_인수인계.pdf 중간 시점 기술 인수인계용 상세 문서(팀 개발자용, 더 기술적).

나머지 참고 문서 4개는 지우지 않고 남겨뒀다 — 과정 중 실제로 나온 실측치가 담겨 있어 나중에 "왜 그렇게 판단했는지" 되짚어볼 근거 자료다. 다만 최신 결론은 이 문서(§4)가 기준이다.

§6 남은 것 딱 두 가지

- 1 **git 커밋 여부 결정.** 코드 수정은 완료돼 실제로 작동하지만, 아직 팀 저장소에는 올라가지 않았다(로컬에만 있음).
- 2 **실제 회계 담당자의 정식 라벨 검증.** 지금 30건의 정답은 AI가 판단한 것이라, 최종적으로 신뢰할 수 있는 숫자를 원하면 사람이 확인해야 한다. (89건 전체로 확대할지도 이때 같이 결정)

이 문서는 2026-08-18 세션 전체 작업을 최종 정리한 것이다. 코드 변경 사항은 `apps/ai/app/agents/risk_review_agent.py`, `apps/core/domain/settlements/views.py`(미커밋)에 있다.